



机器学习·期末模拟试卷

Machine Learning · 2026 春 · 授课老师 顾小东

共 3 套 · 每套 100 分 · 判断/选择/简答/计算/系统设计

仿照课程期末样卷命制，严格遵循课程 PPT 口径。建议先限时 120 分钟闭卷作答，再对照各题下方的【参考答案】与解析。

机器学习 期末模拟试卷（一） A卷

满分 100 分 建议用时 120分钟 开卷，可带纸质资料与计算器；答案见各题。本卷只考课程 PPT 讲授范围。

一、判断题（20 分）

每题2分，共20分。正确记√，错误记×，并说明理由。

1. 线性回归用于预测连续实值标签，属于监督学习；逻辑回归虽然名字里带「回归」，但实际上是一个分类模型。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

线性回归预测实值目标，是监督学习中的回归。逻辑回归用 $\sigma(w^T x + w_0)$ 输出后验概率并以 0.5 为阈值判类，是判别式分类模型，「回归」指其建模对数几率为输入的线性函数这一形式。

2. 在 SVM 中，最大化间隔 $\text{margin} = \frac{2}{\|w\|}$ 等价于最大化 $\frac{1}{2}\|w\|^2$ 。（2分）

A. 正确（√）

B. 错误（×）

参考答案：错误（×）

解析

间隔为 $2/\|w\|$ ，最大化它等价于最小化 $\|w\|$ ，即最小化 $\frac{1}{2}\|w\|^2$ （而非最大化）。约束优化形式为 $\min \frac{1}{2}\|w\|^2$ s.t. $y^{(\ell)}(w^T x^{(\ell)} + w_0) \geq 1$ 。

3. ID3 决策树在每个节点选择「信息增益最大」的属性进行划分；纯净节点（样本全属同一类）的熵为 0。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

信息增益 $\text{Gain}(D, A) = \text{Ent}(D) - \text{Ent}(D | A)$ 衡量划分后纯度提升，ID3 选增益最大者。当 $p = 1$ 时 $\text{Ent} = -1 \cdot \log_2 1 = 0$ ，纯净节点熵为 0。

4. 朴素贝叶斯的核心假设是：给定类别 c 时各特征条件独立，从而 $P(x_1, \dots, x_d | c) \approx \prod_j P(x_j | c)$ ，这把联合概率的参数量从指数级降为线性级。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

正是条件独立假设把联合类条件概率拆成连乘，每类只需估计 $P(c)$ 与 d 个一维条件概率，参数从约 $k^d - 1$ 降到线性级。

5. KNN 有一个计算量很大的训练阶段，但预测非常快。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：错误 (×)

解析

恰好相反。KNN 是惰性学习，训练几乎不计算（只存数据），全部开销在预测阶段——每次预测都要算到所有训练样本的距离。

6. 对 KNN 而言，特征归一化可有可无，对结果没有实质影响。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：错误 (×)

解析

错误。KNN 直接依赖距离，取值范围大的特征会主导距离计算、淹没其它特征，因此必须做 Min-max 或 Z-score 归一化，否则结果会被大量特征带偏。

7. 在 K-means 的每一次迭代中，目标函数（簇内平方和 SSE）单调不增，因此算法保证收敛，但只能收敛到局部最优。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：正确 (✓)

解析

分配步把样本归到最近质心、更新步取簇均值，两步都不增大 SSE，故 SSE 单调不增、算法收敛；但求全局最优是 NP-hard，K-means 只保证局部最优且对初始种子敏感。

8. 逻辑回归的决策边界是一条非线性的曲线（曲面）。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：错误 (×)

解析

错误。决策边界对应 $y = 0.5$ 即 $w^T x + w_0 = 0$ ，是一个线性超平面。Sigmoid 只把线性得分映射为概率，并不改变边界的线性本质，逻辑回归仍是线性分类器。

9. CNN 中的池化层（如 2×2 、步长 2 的最大池化）会对特征图做降采样、缩小空间尺寸，但没有可学习参数，且不改变通道数。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：正确 (✓)

解析

正确。最大/平均池化是固定的取大/取平均操作，无可学习参数； 2×2 、 $S = 2$ 使每个空间维减半（如 $224 \rightarrow 112$ ），通道数不变。

10. 在 Q-learning 的更新式 $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ 中, 方括号内的量是 TD (时序差分) 误差, α 是学习率。 (2分)

A. 正确 (✓)

B. 错误 (×)

参考答案: 正确 (✓)

解析

$r + \gamma \max_{a'} Q(s', a') - Q(s, a)$ 是 TD 误差, 表示「目标值」与「当前估计值」之差; α 控制朝目标更新的步长。

二、选择题 (30 分)

每题3分, 共30分。单选题选最优项; 标注[多选]的为多选, 多选漏选或错选不得分。

1. 下列哪一项**不属于**机器学习的四要素 (Key Elements)? (3分)

A. 数据 (Data)

B. 模型 (Model)

C. 损失函数 (Loss Function)

D. 图形界面 (GUI)

参考答案: D

解析

四要素为数据 (经验)、模型 (假设)、损失函数 (目标)、优化 (改进)。图形界面与机器学习核心要素无关。

2. 线性回归的正规方程 (闭式最优解) 为下列哪一个? (3分)

A. $\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{r}$

B. $\mathbf{w}^* = (X X^T)^{-1} X^T \mathbf{r}$

C. $\mathbf{w}^* = (X^T X) X^T \mathbf{r}$

D. $\mathbf{w}^* = X^T (X X^T)^{-1} \mathbf{r}$

参考答案: A

解析

令损失梯度为零得 $X^T X \mathbf{w} = X^T \mathbf{r}$, 故 $\mathbf{w}^* = (X^T X)^{-1} X^T \mathbf{r}$ 。注意是 $X^T X$ ($d \times d$) 求逆; C 没有求逆。

3. 在逻辑回归中, 对数几率 (logit) 与输入的关系是 $\log \frac{y}{1-y} = w^T x + w_0$, 反解出 y 的表达式是: (3分)

A. $y = w^T x + w_0$

B. $y = \frac{1}{1 + \exp[-(w^T x + w_0)]}$

C. $y = \exp(w^T x + w_0)$

D. $y = \max(0, w^T x + w_0)$

参考答案: B

解析

logit 的反函数即 Sigmoid (逻辑) 函数 $y = \frac{1}{1 + e^{-(w^T x + w_0)}}$, 直接给出后验概率 $P(C_1 | x)$, 平滑可导便于优化。

4. 二分类交叉熵损失 $\ell = -r \log y - (1 - r) \log(1 - y)$ 中, 当真实标签 $r = 0$ 时, 损失退化为: (3分)

A. $-\log y$

B. $-\log(1 - y)$

C. 0

D. $-\log y - \log(1 - y)$

参考答案: B

解析

$r = 0$ 时第一项 $-r \log y = 0$, 只剩 $-(1 - r) \log(1 - y) = -\log(1 - y)$, 即希望最大化 $\log P(C_2 | x)$ 。

5. 训练集共有 N 个样本。当取 $K = N$ 时, KNN 的预测行为是什么? (3分)

- A. 对每个测试点都精确分类, 无误差
- B. 总是预测训练集中的全局多数类, 丧失判别力
- C. 等价于最近邻 ($K = 1$)
- D. 无法定义, 算法会报错

参考答案: B

解析

$K = N$ 时所有训练样本都参与投票, 无论测试点在哪, 多数类永远胜出, 模型退化为常数预测器。

6. PCA 的优化问题 $\max_u u^T S u$ s.t. $u^T u = 1$ (S 为协方差矩阵) 通过拉格朗日法求解后, 归结为求解什么? (3分)

- A. 梯度下降迭代
- B. 协方差矩阵 S 的特征分解 $Su = \lambda u$
- C. 矩阵求逆 S^{-1}
- D. Softmax 归一化

参考答案: B

解析

令 $\nabla_u L = 0$ 得 $Su = \lambda u$, 即 u 为特征向量、 λ 为特征值 (=投影方差)。取最大 k 个特征值对应的特征向量为主成分。

7. 输入特征图尺寸 $N = 7$, 卷积核 $F = 3$, 填充 $P = 0$, 步长 stride = 2, 卷积输出的空间尺寸为多少? (公式 $\lfloor \frac{N+2P-F}{S} \rfloor + 1$) (3分)

- A. 7×7
- B. 5×5
- C. 3×3
- D. 2×2

参考答案: C

解析

代入公式: $\frac{7+0-3}{2} + 1 = \frac{4}{2} + 1 = 2 + 1 = 3$, 故输出 3×3 。增大步长会缩小输出尺寸。

8. 强化学习中, Q 函数的贝尔曼递归形式 $Q(s_t, a_t) = r_t + \gamma \max_{a'} Q(s_{t+1}, a')$ 来源于: (3分)

- A. 对折扣回报 $R_t = \sum_i \gamma^i r_{t+i}$ 提取首项 r_t , 并把余项写成 γ 倍的下一步最优值
- B. 对损失函数求二阶导
- C. Softmax 归一化
- D. 拉普拉斯平滑

参考答案: A

解析

把折扣回报 $R_t = r_t + \gamma r_{t+1} + \dots$ 中除首项外提出公因子 γ , 余项对应下一状态的最优 Q, 得到递归式, 这是 Q-learning/DQN 目标值的依据。

9. [多选] 某模型在训练集上误差仅 2%，但在测试集上误差高达 28%。下列哪些做法**有助于**缓解这一现象？（3分）

- A. 增加训练数据 B. 增大正则化系数 λ （加强 L_1/L_2 惩罚）
C. 提高模型复杂度（如增加更多层、更多特征） D. 使用早停（Early Stopping）

参考答案：A、B、D

解析

训练误差极低但测试误差高是典型**过拟合**。增加数据、增大正则化、早停都能抑制过拟合。C 错：提高模型复杂度会**加重**过拟合，它是治欠拟合的手段。

10. [多选] 下列关于 K-means 的说法, 正确的有哪些? (3分)

- A. 它是无监督聚类算法, 训练不使用标签
B. 质心被定义为簇内所有样本的均值
C. 目标函数是簇内平方和 $J = \sum_k \sum_{x \in C_k} \|x - \mu_k\|^2$
D. 它能自动发现任意形状的簇并识别噪声点

参考答案：A、B、C

解析

A、B、C 正确：K-means 无监督、质心取簇均值、最小化簇内平方和（SSE）。D 错：K-means 隐含假设簇为球形，对非球形簇效果差，并不能自动识别任意形状的簇或噪声点。

三、简答题 (20 分)

共20分。

1. 请按「假设/模型 → 损失函数 → 优化方法」三段式，对比逻辑回归与 SVM 这两个线性分类器，并指出二者最关键的差别。（6分）

参考答案

逻辑回归 (Logistic Regression)

- 模型: $y = \sigma(w^T x + w_0) = \frac{1}{1 + e^{-(w^T x + w_0)}}$, 输出后验概率 $P(C_1 | x)$ 。
- 损失: 交叉熵 $\ell = -r \log y - (1 - r) \log(1 - y)$ (等价于最大化伯努利似然)。
- 优化: 梯度下降, 更新 $w \leftarrow w + \eta \sum_{\ell} (r^{(\ell)} - y^{(\ell)}) x^{(\ell)}$ 。

SVM

- 模型：线性判别 $w^T x + w_0$ ，寻找**最大间隔**超平面；约束 $y^{(\ell)}(w^T x^{(\ell)} + w_0) \geq 1$ ，最大化间隔 $2/\|w\|$ 等价于 $\min \frac{1}{2}\|w\|^2$ 。
- 损失：合页损失 $\max(0, 1 - y(w^T x + w_0))$ ，体现最大间隔思想。
- 优化：梯度下降。

关键区别：逻辑回归对所有样本都计损失、直接输出概率；SVM 追求最大间隔，对已分对且足够远（间隔分 ≥ 1 ）的点零损失，泛化好但不直接给出概率。两者都是线性模型，复杂度均约 $O(d)$ 。

2. 简述朴素贝叶斯中的「零计数问题」会带来什么后果，写出拉普拉斯平滑公式，并说明分母为什么要加上属性取值种类数 $|x|$ 。（7分）

参考答案

零计数问题：若训练集中类别 c 的样本里某属性取值 x_i 从未出现，则 $\hat{P}(x_i | c) = 0$ 。由于朴素贝叶斯是连乘 $P(c) \prod_j P(x_j | c)$ ，任一项为 0 会使整体后验为 0，造成「一票否决」——即便其它特征都强烈支持类别 c ，也永远不会判为 c 。

拉普拉斯平滑：给每个取值加一个虚拟计数 1：

$$\hat{P}(x_i | c) = \frac{\#(x_i, c) + 1}{\sum_x \#(x, c) + |x|}$$

分母加 $|x|$ 的原因：分子对每个取值都加了 1，共有 $|x|$ 种取值，分子总增量为 $|x|$ ，分母必须同步加 $|x|$ 才能保证 $\sum_i \hat{P}(x_i | c) = 1$ ，即概率归一化仍成立。文本分类中 $|x| = |Vocab|$ 为词表大小。

3. 用同一个业务场景——「电商用户行为数据」，分别给出**有监督学习、无监督学习、强化学习**三种提法，指出各自的数据形式、学习目标，并各举一个课程中的代表模型。（7分）

参考答案

三者的区别不在数据来源，而在**有没有标签、反馈是什么形式**。

① 有监督学习

- 提法：已知部分用户的流失标签（churn=是/否），训练模型预测新用户是否流失。
- 数据：带标签的样本 (x, y) ；目标：学「输入→标签」的映射。
- 代表模型：逻辑回归 / SVM / 决策树（分类），损失常用交叉熵。

② 无监督学习

- 提法：不知道用户该分几类，把行为相似的用户自动分组、挖掘潜在人群。
- 数据：只有输入 x 、无标签；目标：发现数据的内在结构。
- 代表模型：K-means（聚类）、PCA / 自编码器（降维）。

③ 强化学习

- 提法：让推荐智能体给用户推商品，点击/下单给奖励，让它在交互中学会最大化长期收益的策略。
- 数据：状态-动作对 + 奖励；目标：学策略（状态→动作）使长期折扣回报 $R_t = \sum_i \gamma^{i-t} r_i$ 最大。
- 代表模型：Q-learning / DQN。

易混提醒：聚类（无监督）与分类（有监督）都「分组」，区别在分类有现成标签、聚类没有；强化学习的「奖励」不是标签，它只告诉你「这步好不好」，不告诉你「正确动作是什么」。

四、计算题（20 分）

共20分。要求写出计算步骤。

1. 某电商平台用决策树 (ID3) 判断一条商品评论是否为「好评」。训练集有 6 条评论, 特征为「是否含正面词 (Pos ∈ {是, 否})」, 标签为「好评 Good ∈ {是, 否}」: | ID | 含正面词 Pos | 好评 Good | |----|----|----| | 1 | 是 | 是 | | 2 | 是 | 是 | | 3 | 是 | 否 | | 4 | 否 | 否 | | 5 | 否 | 否 | | 6 | 否 | 是 | 请: (1) 计算根节点的信息熵 $Ent(D)$; (2) 按属性「含正面词」划分, 计算条件熵 $Ent(D | Pos)$ 与信息增益 $Gain(D, Pos)$ 。($\log_2 3 \approx 1.585$, 结果保留 3 位小数) (10分)

参考答案

第1步: 算根节点熵 $Ent(D)$ 。

6 条评论中「好评=是」有 ID 1,2,6 共 3 条, 「好评=否」有 ID 3,4,5 共 3 条, 正好对半 (3:3)。

$$Ent(D) = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = -0.5 \times (-1) - 0.5 \times (-1) = \boxed{1.000}$$

(两类均匀分布时熵达到最大值 1 bit, 最不纯。)

第2步: 按「含正面词」划分成两个子集。

- $D_{是}$: ID 1,2,3 → 好评 2 个 (1,2)、差评 1 个 (3), 共 3 条。
- $D_{否}$: ID 4,5,6 → 好评 1 个 (6)、差评 2 个 (4,5), 共 3 条。

第3步: 分别算两个子集的熵。两个子集比例对称 (2:1 与 1:2), 熵相同:

$$Ent(D_{是}) = -\frac{2}{3} \log_2 \frac{2}{3} - \frac{1}{3} \log_2 \frac{1}{3}$$

其中 $\log_2 \frac{2}{3} = \log_2 2 - \log_2 3 = 1 - 1.585 = -0.585$, $\log_2 \frac{1}{3} = -\log_2 3 = -1.585$:

$$= -\frac{2}{3} \times (-0.585) - \frac{1}{3} \times (-1.585) = 0.390 + 0.528 = 0.918$$

同理 $Ent(D_{否}) = 0.918$ 。

第4步: 加权平均得条件熵 (两子集各 3 条, 权重都是 3/6)。

$$Ent(D | Pos) = \frac{3}{6} \times 0.918 + \frac{3}{6} \times 0.918 = \boxed{0.918}$$

第5步: 信息增益 = 划分前熵 - 划分后条件熵。

$$Gain(D, Pos) = Ent(D) - Ent(D | Pos) = 1.000 - 0.918 = \boxed{0.082}$$

> 结论: 用「含正面词」划分只把不纯度从 1.000 降到 0.918, 信息增益仅 0.082, 说明这个特征区分「好评/差评」的能力较弱 (因为含正面词的评论里仍混有差评)。若有信息增益更大的其它特征, ID3 会优先选它。

2. 电商平台用 Q-learning 训练一个推荐智能体。在状态 s 下智能体选了动作 a (「推送优惠券」), 环境给奖励 $r = 4$ 并转移到新状态 s' 。已知学习率 $\alpha = 0.5$, 折扣因子 $\gamma = 0.9$, 当前 $Q(s, a) = 2$, 新状态 s' 有三个可选动作, 其当前 Q 值为 $Q(s', a_1) = 10$ 、 $Q(s', a_2) = 3$ 、 $Q(s', a_3) = 6$ 。请用更新式 $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ 计算: (1) TD 目标值; (2) TD 误差; (3) 更新后的 $Q(s, a)$ 。 (10分)

参考答案

第1步: 在新状态 s' 里取最大的 Q 值 $\max_{a'} Q(s', a')$ 。

$$\max_a Q(s', a') = \max(10, 3, 6) = 10$$

(Q-learning 假设到了 s' 之后会走最优动作, 故目标里用 $\max$ 。)

第2步: 算 TD 目标值 = 即时奖励 + 折扣后的未来最优 Q。

$$\text{target} = r + \gamma \max_{a'} Q(s', a') = 4 + 0.9 \times 10 = 4 + 9 = 13$$

第3步: 算 TD 误差 = 目标 - 当前估计。

$$\delta = \text{target} - Q(s, a) = 13 - 2 = 11$$

$\delta = 11 > 0$, 说明「实际比原来估计的好」, 应把该动作的 Q 值往上调。

第4步: 按学习率 α 把旧值朝目标方向挪。

$$Q(s, a) \leftarrow Q(s, a) + \alpha \delta = 2 + 0.5 \times 11 = 2 + 5.5 = 7.5$$

> 理解: $\alpha = 0.5$ 表示「朝目标走一半」。若 $\alpha = 1$ 则直接跳到目标 13; 这里 Q 从 2 更新到 7.5, 正是 2 与目标 13 的中点。

五、系统设计题 (10 分)

共10分。

1. 某电商平台希望搭建一套智能分析系统，包含两个任务：（任务一）对海量商品评论做**情感分类**，自动标注为「好评 / 中评 / 差评」三类；（任务二）基于用户的浏览、购买、停留时长等行为数据，**预测用户在未来一个月内是否会流失**。请针对这两个任务，按以下要点给出完整设计方案：问题建模（监督/无监督？分类/回归？）→ 数据与特征 → 模型选择（用课程模型并说明理由）→ 损失函数 → 训练与优化 → 评估指标 → 可能的问题与改进。（10分）

参考答案

一、问题建模

- 任务一（评论情感分类）：有人工标注的好评/中评/差评标签 → **有监督学习**；输出是 3 个离散类别 → **多分类问题**。
- 任务二（用户流失预测）：有历史「是否流失」标签 → **有监督学习**；输出是「流失/不流失」二类 → **二分类问题**（若要输出流失概率以便排序干预，更需要概率化模型）。

二、数据与特征

- 任务一：评论文本。先分词、去停用词，用词袋/词频或词嵌入（Word Embedding）表示；标签来自人工标注或商品星级映射。
- 任务二：用户行为表。特征如近 30 天浏览次数、购买金额、登录天数、平均停留时长、距上次下单天数、退货率等。数值特征需做归一化（Min-max 或 Z-score）。

三、模型选择（课程模型）

- 任务一：① **朴素贝叶斯**——课程指出它最适合文本分类，训练只需一遍计数、预测快、天然支持多分类，是强基线；② 或 **Softmax 回归**——直接输出 3 类的概率分布（ $K=2$ 时退化为逻辑回归），可微便于梯度优化。
- 任务二：**逻辑回归**——二分类且需要输出「流失概率」以便按阈值预警/干预，逻辑回归用 Sigmoid 直接给出后验概率，简单、可解释、复杂度 $O(d)$ ；若更看重规则可解释性（给业务方看），可用**决策树**。

四、损失函数

- 任务一（Softmax 回归）：多分类交叉熵 $L_{CE} = -\sum_i r_i \log y_i$ （ r 为 one-hot）；朴素贝叶斯则用极大似然（频率计数）估计参数，无需梯度损失。
- 任务二（逻辑回归）：二分类交叉熵 $\ell = -r \log y - (1-r) \log(1-y)$ 。

五、训练与优化

- 朴素贝叶斯：扫描训练集计数估计 $P(c)$ 与 $P(x_j | c)$ ，对未出现词用**拉普拉斯平滑**避免零概率一票否决。
- 逻辑回归/Softmax 回归：用**梯度下降**迭代，梯度形如「(预测-标签)×输入」，配合 L_2 正则化缓解过拟合、用交叉验证/留出法选超参数与阈值。

六、评估指标

- 任务一：多分类的准确率、各类精确率/召回率/F1，混淆矩阵（看中评是否易被误判）。
- 任务二：因流失样本通常**类别不平衡**，不能只看准确率，应看精确率、召回率、F1、AUC；业务上更关注「能召回多少真流失用户」（召回率）。

七、可能的问题与改进

- 类别不平衡（流失用户少、中评少）：重采样、调整类别权重或决策阈值。
- 朴素贝叶斯的条件独立假设在文本中被违反，但实践效果仍好；若精度不足可换更强模型或引入词嵌入。
- 过拟合：增加数据、加正则化、早停、交叉验证。
- 标签噪声、概念漂移（用户行为随时间变化）：定期重新训练、滚动更新模型。

机器学习 期末模拟试卷（二） B卷

满分 100 分 建议用时 120分钟 开卷，可带纸质资料与计算器；答案见各题

一、判断题（20 分）

每题2分，共20分。正确记√，错误记×，并说明理由。

1. 欠拟合 (Underfitting) 通常表现为：训练误差很低，但测试误差很高。（2分）

- A. 正确 (√) B. 错误 (×)

参考答案：错误 (×)

解析

这是过拟合的表现。欠拟合是模型太简单、容量不足，**训练误差和测试误差都高**；过拟合才是训练误差低、测试误差高、二者差距大。

2. 在决策树 ID3 算法中，若某属性把数据划分后每个子集都完全纯净（熵为 0），则该属性在这一步的信息增益等于划分前根节点的熵 $H(D)$ 。（2分）

- A. 正确 (√) B. 错误 (×)

参考答案：正确 (√)

解析

信息增益 $\text{Gain}(D, A) = H(D) - H(D|A)$ 。各子集纯净则条件熵 $H(D|A) = 0$ ，故增益恰等于 $H(D)$ ，达到该步最大值，ID3 会优先选它分裂。

3. 朴素贝叶斯在估计某个 $P(x_j|c)$ 时若出现计数为 0，会导致整个后验连乘结果为 0；为避免这一点常用拉普拉斯平滑。（2分）

- A. 正确 (√) B. 错误 (×)

参考答案：正确 (√)

解析

由于 $P(c) \prod_j P(x_j|c)$ 是连乘，任一因子为 0 都会使整体为 0。拉普拉斯平滑给计数加一个小常数，避免零概率。

4. K 近邻 (K-NN) 属于惰性学习：它在训练阶段就拟合好模型参数，预测时只需直接套用参数公式。（2分）

- A. 正确 (√) B. 错误 (×)

参考答案：错误 (×)

解析

K-NN 是惰性学习，但「训练阶段拟合参数」的描述错误。它**没有显式训练过程**，全部计算都在预测时进行：预测时才计算待测点到各训练样本的距离并做多数投票。

5. SVM 中最大化间隔 $\text{margin} = 2/\|w\|$ 等价于最小化 $\frac{1}{2}\|w\|^2$ ，这是一个凸的二次规划问题。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：正确 (✓)

解析

间隔 $= 2/\|w\|$ ，最大化它等价于最小化 $\|w\|$ ，即最小化 $\frac{1}{2}\|w\|^2$ ，在线性约束 $y^{(\ell)}(w^T x^{(\ell)} + w_0) \geq 1$ 下构成凸二次规划。

6. 卷积层中，输出特征图的通道数由输入图像的通道数决定，与滤波器（卷积核）的个数无关。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：错误 (×)

解析

恰好相反：输出通道数 = 滤波器个数；而每个滤波器的深度才必须等于输入通道数。 K 个滤波器产生 K 张特征图，与 N, F, S, P 无关。

7. 池化层（如 2×2 、步长 2 的最大池化）没有可学习的参数，且不改变特征图的通道数。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：正确 (✓)

解析

池化只是固定的取最大/取平均操作，无可训练参数；它只在空间维度上降采样（如 $4 \times 4 \rightarrow 2 \times 2$ ），通道数保持不变。

8. 自注意力中对点积分数除以 $\sqrt{d_k}$ ，是为了在 d_k 较大时控制点积的方差，避免 softmax 进入梯度极小的饱和区。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：正确 (✓)

解析

d_k 大时点积方差正比于 d_k 、数值波动大，会让 softmax 饱和、梯度趋近 0。除以 $\sqrt{d_k}$ 把方差缩回合理范围，稳定训练。

9. 在 Q-learning 的更新目标 $r + \gamma \max_{a'} Q(s', a')$ 中使用 $\max$ ，意味着它学习的是最优策略对应的 Q 值，属于离策略 (off-policy) 方法。（2分）

A. 正确 (✓)

B. 错误 (×)

参考答案：正确 (✓)

解析

更新目标用 $\max_{a'}$ （贪婪地假设下一步走最优动作），因此学到的是最优策略的 Q 值；采样策略（如 ϵ -greedy）与目标策略不同，是离策略。

10. 在 GAN 的训练中, 生成器 G 的目标是最大化目标函数 $V(G, D)$, 从而更好地分辨真假样本。 (2分)

A. 正确 (✓)

B. 错误 (×)

参考答案: 错误 (×)

解析

分辨真假、最大化 V 的是判别器 D 。生成器 G 的目标是**最小化** V , 即生成尽量骗过 D 的假样本。这是 $\min_G \max_D$ 的对抗博弈。

二、选择题 (30 分)

每题3分, 共30分。单选选最优项; 标注[多选]的为多选。

1. 随着模型复杂度从低到高变化, 训练误差与测试误差的典型走势是: (3分)

A. 训练误差与测试误差都单调下降

B. 训练误差单调下降, 测试误差先降后升 (U 形)

C. 训练误差先降后升, 测试误差单调下降

D. 两者都先升后降

参考答案: B

解析

复杂度增大时训练误差单调下降; 测试误差先降 (欠拟合改善) 后升 (开始过拟合), 呈 U 形, 最优点在中间的合适复杂度处。

2. 一个二分类节点含 4 个正样本、4 个负样本, 其信息熵 $H(D)$ (以 2 为底) 等于: (3分)

A. 0

B. 0.5

C. 1

D. 2

参考答案: C

解析

正负各占 $1/2$, $H(D) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = \frac{1}{2} + \frac{1}{2} = 1$ 。两类等量时熵最大 (=1 bit)。

3. 关于 K-NN 中 K 值的选择, 下列说法正确的是: (3分)

A. K 越小决策边界越平滑、越抗噪声

B. K 太小容易过拟合 (对噪声敏感), K 太大容易欠拟合 (边界过平滑)

C. K=N 时模型对每个点都给出不同预测

D. K 的取值不影响决策边界形状

参考答案: B

解析

K 太小 (如 K=1) 边界破碎、对噪声敏感即过拟合; K 太大边界过平滑即欠拟合; K=N 时永远预测多数类。

4. 逻辑回归用于二分类时，其输出 $y = \text{sigmoid}(w^T x + w_0)$ 应解释为：（3分）

- A. 样本到决策边界的几何距离
- B. 后验概率 $P(C_1|x)$
- C. 输入的线性组合本身
- D. 类别的整数编号

参考答案：B

解析

逻辑回归从 log-odds 线性假设出发，Sigmoid 把线性打分映射到 $(0, 1)$ ，输出是后验概率 $P(C_1|x)$ ，再阈值化得类别。

5. 某 SVM 样本真实标签 $y = -1$ ，模型给出 $w^T x + w_0 = -0.4$ ，间隔分 $m = y(w^T x + w_0)$ 。其合页损失 $\max(0, 1 - m)$ 等于：（3分）

- A. 0
- B. 0.6
- C. 0.4
- D. 1.4

参考答案：B

解析

$m = (-1) \times (-0.4) = 0.4$ ，分对但在间隔内 ($m < 1$)。合页损失 $\max(0, 1 - 0.4) = 0.6$ ，需要线性惩罚把它推到间隔外。

6. 输入特征图尺寸 $N = 32$ ，卷积核 $F = 5$ ，步长 $S = 1$ ，要使卷积后空间尺寸保持 32×32 (same 卷积)，单边填充 P 应取：（3分）

- A. 1
- B. 2
- C. 3
- D. 0

参考答案：B

解析

$S = 1$ 时保持尺寸取 $P = \frac{F-1}{2} = \frac{5-1}{2} = 2$ 。验证： $(32 + 2 \times 2 - 5)/1 + 1 = 31 + 1 = 32$ 。

7. 在 Transformer 解码器中使用 Masked Multi-Head Attention 的主要目的是：（3分）

- A. 压缩模型参数量
- B. 在自回归生成第 i 个词时只允许关注已生成的词，屏蔽未来词，防止信息泄露
- C. 把输入序列双向编码
- D. 替代位置编码

参考答案：B

解析

掩码注意力屏蔽未来位置，保证第 i 步只依赖 $1 \dots i$ 的输出，符合自回归生成、避免「偷看答案」。编码器侧注意力可双向。

8. PCA 通过拉格朗日法求解 $\max_u u^T S u$ s.t. $u^T u = 1$ 后，归结为对协方差矩阵 S 做特征分解 $Su = \lambda u$ 。这里特征值 λ 的含义是：（3分）

- A. 投影到该主成分方向上的方差
- B. 样本数量
- C. 原始数据的均值
- D. 重构误差恒为 0

参考答案：A

解析

约束优化解满足 $Su = \lambda u$ ，且 $u^T Su = \lambda$ ，即特征值等于数据投影到该特征向量方向后的方差。取最大的 k 个特征值对应的特征向量即主成分。

9. 下列关于强化学习中 Q 函数与 V 函数的说法，正确的是：（3分）

- A. Q 只评估状态，V 评估状态加动作
- B. Q 评估「状态 + 动作」的价值，V 只评估「状态」的价值
- C. 二者完全等价、可互换
- D. Q 与 V 都不依赖折扣因子 γ

参考答案：B

解析

$Q(s, a)$ 是状态-动作价值， $V(s)$ 是状态价值。优势函数 $A(s, a) = Q(s, a) - V(s)$ 正是二者之差，二者都基于折扣回报、含 γ 。

10. [多选] 下列关于「监督 / 无监督 / 强化学习」三类范式的描述，正确的有：（3分）

- A. K-means 聚类属于无监督学习，只用输入 x 、靠数据内在结构分组
- B. 用已标注的「是否流失」标签训练流失预测模型属于有监督学习
- C. 强化学习靠与环境交互得到的标量奖励（可延迟）学习策略，而非现成标签
- D. PCA 是一种有监督的分类算法

参考答案：A、B、C

解析

A、B、C 正确。D 错：PCA 是**无监督降维**方法（找方差最大方向），不是分类、不需要标签。

三、简答题（20 分）

共20分。

1. 请按「假设/模型 → 损失函数 → 优化」三段式，对比 K-means 聚类与 PCA 降维两种无监督方法的核心思想，并各指出一个易混点或局限。（7分）

参考答案

K-means 聚类

- 模型/假设：用 k 个**质心**代表 k 个簇，每个点归属到距离最近的质心；簇由「质心 + 隶属关系」描述。
- 损失（目标）：最小化簇内平方和 SSE/WSS $\sum_i \sum_{x \in C_i} \|x - \mu_i\|^2$ 。
- 优化：交替两步迭代——①分配（每点分到最近质心）②更新（质心取簇内均值），重复直至收敛。
- 易混/局限：对**初始种子敏感**、可能陷入局部最优（K-means++ 改善初始化）；需要预先指定 k （可用肘部法）。

PCA 降维

- 模型/假设：在数据中寻找**方差最大**的正交方向（主成分），用前 k 个方向线性投影实现降维。
- 损失（目标）：等价两种视角——最大化投影方差 $\max_u u^T S u$ s.t. $u^T u = 1$ ，或最小化重构误差。
- 优化：解析解——对协方差矩阵 S 做**特征分解** $Su = \lambda u$ ，取最大 k 个特征值对应的特征向量。
- 易混/局限：PCA 是**线性**降维、有解析解；它无监督地保留方差但不一定保留对分类最有用的方向。

对比小结：K-means 解决「聚类（分组）」、靠迭代、对初始化敏感；PCA 解决「降维（找结构）」、靠特征分解、是解析解。二者都不需要标签。

2. 简述卷积相比全连接（MLP）在处理图像时的两个核心机制，并说明它们各自带来的好处。（6分）

参考答案

核心机制一：局部连接 (Local Connectivity)

- 每个隐藏单元只连接输入图像的一个**局部 patch**（如 5×5 区域），而非整张图。
- 好处：保留了图像的**二维空间结构**，符合「图像的局部相关性」先验；参数也随之减少。

核心机制二：权值共享 (Weight Sharing)

- 同一个卷积核在整张图上**滑动复用同一组权重**去检测同一种特征。
- 好处：①参数量与图像大小无关、大幅减少（不易过拟合、训练更快）；②带来**平移等变性**——同一特征出现在不同位置都能被检测到。

对比 MLP 的问题：MLP 把图像拉直会破坏空间结构、对局部不敏感、平移不变性差、参数爆炸（如 $32 \times 32 \times 3$ 全连接到 1024 个神经元需约 314 万参数，而一个 $5 \times 5 \times 3$ 卷积核仅 76 个参数）。因此卷积「局部连接 + 权值共享」既省参数又保留空间信息。

3. 在强化学习中，策略梯度（REINFORCE）方差较大。请说明 Actor-Critic 如何用「优势函数」降低方差，并指出 TD 误差与优势函数的关系。（7分）

参考答案

REINFORCE 的问题：直接用整条轨迹的回报 $R(\tau)$ 给 $\nabla_{\theta} \log \pi_{\theta}(a_t|s_t)$ 加权，回报方差大、训练不稳定。

Actor-Critic 的做法：

- **Actor**（策略网络，policy-based）输出动作；**Critic**（价值网络，value-based）估计状态值 $V(s)$ 。
- 用**优势函数** $A(s, a) = Q(s, a) - V(s)$ 替代原始回报 R 来加权：

$$\nabla J(\theta) = \sum_t A(s_t, a_t) \nabla_{\theta} \log \pi_{\theta}(a_t|s_t)$$

- 优势衡量「该动作比平均水平好多少」，相当于减去一个基线 $V(s)$ ，在不引入偏差的前提下**显著降低方差**。

TD 误差与优势的关系：单步 TD 误差 $\delta = r + \gamma V(s') - V(s)$ 是优势函数 $A(s, a)$ 的一个**无偏估计**（因为 $\mathbb{E}[r + \gamma V(s')] = Q(s, a)$ ）。于是 A2C 直接用 δ_t 代替 A ：

$$\nabla J(\theta) = \sum_t \delta_t \nabla_{\theta} \log \pi_{\theta}(a_t|s_t)$$

Critic 同时通过最小化 δ^2 做值回归来训练。

四、计算题（20 分）

共20分。要求写出计算步骤。

1. 某卷积神经网络的一层：输入特征图为 $28 \times 28 \times 3$ ，使用 **16 个** 5×5 的卷积核，步长 $S = 1$ ，单边填充 $P = 2$ 。(1) 求该卷积层输出特征图的空间尺寸与输出体的完整形状（含通道数）。(2) 求该卷积层的参数总量（含偏置）。(3) 设卷积输出后某一通道的左上角 4×4 区域为

$$X = \begin{bmatrix} 6 & 2 & 8 & 4 \\ 1 & 7 & 3 & 5 \\ 9 & 2 & 1 & 6 \\ 3 & 8 & 5 & 0 \end{bmatrix}$$

对该区域做 2×2 、步长 $S = 2$ 的**最大池化**，写出 2×2 的池化结果。（10分）

参考答案

(1) 输出空间尺寸

用输出尺寸公式 输出 = $\left\lfloor \frac{N + 2P - F}{S} \right\rfloor + 1$:

$$\frac{28 + 2 \times 2 - 5}{1} + 1 = \frac{28 + 4 - 5}{1} + 1 = \frac{27}{1} + 1 = 28$$

空间尺寸为 28×28 （这是 same 卷积，尺寸不变）。

输出通道数 = 滤波器个数 = 16，故输出体形状为 $28 \times 28 \times 16$ 。

(2) 参数总量

每个卷积核的深度必须等于输入通道数 3，故单核权重 = $5 \times 5 \times 3 = 75$ ，加 1 个偏置 = 76。

共 16 个核：

$$76 \times 16 = 1216 \text{ 个参数}$$

(3) 最大池化 (2×2 , $S = 2$)

输出尺寸 $\frac{4-2}{2} + 1 = 2$ ，即 2×2 。窗口互不重叠，把 X 切成 4 个角块取最大值：

- 左上 $\begin{bmatrix} 6 & 2 \\ 1 & 7 \end{bmatrix} \Rightarrow \max = 7$
- 右上 $\begin{bmatrix} 8 & 4 \\ 3 & 5 \end{bmatrix} \Rightarrow \max = 8$
- 左下 $\begin{bmatrix} 9 & 2 \\ 3 & 8 \end{bmatrix} \Rightarrow \max = 9$
- 右下 $\begin{bmatrix} 1 & 6 \\ 5 & 0 \end{bmatrix} \Rightarrow \max = 6$

$$\text{MaxPool}(X) = \begin{bmatrix} 7 & 8 \\ 9 & 6 \end{bmatrix}$$

2. 智能体在状态 s 选择动作 a ，环境给出即时奖励 $r = 10$ ，并转移到新状态 s' 。已知学习率 $\alpha = 0.5$ 、折扣因子 $\gamma = 0.8$ ，当前 Q 表中 $Q(s, a) = 4$ ；新状态 s' 下三个可选动作的 Q 值为 $Q(s', a_1) = 12$ 、 $Q(s', a_2) = 7$ 、 $Q(s', a_3) = 9$ 。请用 Q-learning 更新公式 $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ ，分步计算更新后的 $Q(s, a)$ 。（10分）

参考答案

第一步：求新状态下的最大 Q 值 $\max_{a'} Q(s', a')$

$$\max_a Q(s', a') = \max(12, 7, 9) = 12$$

（Q-learning 在更新目标里取 max，假设到了 s' 后会走最优动作。）

第二步：算 TD 目标 $\text{target} = r + \gamma \max_{a'} Q(s', a')$

$$\text{target} = 10 + 0.8 \times 12 = 10 + 9.6 = 19.6$$

第三步：算 TD 误差 $\delta = \text{target} - Q(s, a)$

$$\delta = 19.6 - 4 = 15.6$$

$\delta > 0$ ，说明这一步「实际比原来估计的好」，应把该动作的 Q 值往上调。

第四步：按学习率把旧值朝目标方向更新

$$Q(s, a) \leftarrow Q(s, a) + \alpha \delta = 4 + 0.5 \times 15.6 = 4 + 7.8 = 11.8$$

更新后 $Q(s, a) = 11.8$ 。（ $\alpha = 0.5$ 表示只朝目标走一半：从 4 移向目标 19.6 的中点附近。）

五、系统设计题（10 分）

共10分。

1. 某短视频平台希望：(A) **自动给视频封面图做内容分类**（风景 / 人物 / 美食 / 游戏 …），(B) 在此基础上**为用户做个性化视频推荐**。请按完整机器学习流程设计方案：问题建模 → 数据与特征 → 模型选择（用课程模型并说明理由）→ 损失函数 → 训练与优化 → 评估 → 可能问题与改进。（10分）

参考答案

一、问题建模

- 任务 A（封面分类）：输入一张封面图，输出所属内容类别（风景/人物/美食/游戏…）→ **多分类**的图像分类问题。
- 任务 B（个性化推荐）：给定用户与候选视频，预测用户是否会点击/观看 → 可建模为**二分类**（点击概率预测，CTR），或建模为**强化学习**（推荐智能体，按用户反馈最大化长期收益）。

二、数据与特征

- 任务 A：封面图像 + 人工/弱标注的类别标签。输入做归一化、数据增强（翻转、裁剪、色彩抖动）以缓解过拟合。
- 任务 B：用户侧特征（历史观看类别分布、停留时长、互动）、视频侧特征（由任务 A 得到的内容类别、时长、作者）、上下文（时间、设备）。视频的内容类别向量正好由任务 A 提供，打通两任务。

三、模型选择（课程模型 + 理由）

- 任务 A：用 **CNN**（卷积神经网络）。理由：卷积的「局部连接 + 权值共享」保留图像空间结构、参数少、平移等变，远优于把图像拉直的 MLP；用堆叠的卷积+池化层提取层次特征，最后接 Softmax 输出多类概率。
- 任务 B：
 - 基线：把用户/视频特征拼成向量，用 **逻辑回归 / MLP** 做点击概率（CTR）二分类，简单可解释、易上线。
 - 进阶：用 **强化学习（DQN / 策略梯度 Actor-Critic）** 把推荐看作序贯决策，状态=用户当前画像、动作=推哪个视频、奖励=点击/完播/时长，优化**长期折扣回报**而非单次点击。

四、损失函数

- 任务 A：多分类**交叉熵** $L_{CE} = -\sum_i r_i \log y_i$ （配 Softmax）。
- 任务 B：CTR 用二分类**交叉熵**；若用 DQN 则用值回归 MSE $\|(r + \gamma \max_{a'} Q(s', a')) - Q(s, a)\|^2$ ，策略梯度用 $-\sum_t A_t \log \pi_\theta(a_t | s_t)$ 。

五、训练与优化

- 用小批量**梯度下降 / 反向传播**训练；CNN 可用迁移学习/预训练加速收敛。
- 正则化（L2、Dropout、数据增强、早停）防过拟合；DQN 用**经验回放**打散样本相关性、用目标网络稳定训练。

六、评估

- 任务 A：准确率、各类别精确率/召回率、混淆矩阵；用留出/交叉验证看泛化。
- 任务 B：离线用 CTR/AUC、Top-K 命中率；在线用 A/B 测试看点击率、完播率、留存等长期指标。

七、可能问题与改进

- 类别不平衡（某些内容样本少）：重采样、加权损失。
- 标签噪声/封面与正文不符：清洗、弱监督。
- 推荐**信息茧房 / 探索不足**：用 ϵ -greedy 等保留探索，平衡探索与利用。
- 冷启动（新用户/新视频）：用任务 A 的内容类别做基于内容的召回兜底。
- 反馈延迟与长期收益：用强化学习优化长期回报，而非只追单次点击。

机器学习 期末模拟试卷（三） C卷

满分 100 分 建议用时 120分钟 开卷，可带纸质资料与计算器；答案见各题

一、判断题（20 分）

每题2分，共20分。正确记√，错误记×，并说明理由。

1. K-means 的目标函数是簇内平方和 $J = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2$ ，其"更新质心"步把每个簇的质心更新为该簇样本的算术均值，这一步能保证 J 不会增大。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

固定隶属关系时，令 $\frac{\partial}{\partial \mu_k} \sum_{x \in C_k} \|x - \mu_k\|^2 = 0$ 解得 $\mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$ 恰为均值，是该簇平方误差的最小点；分配步与更新步都单调不增 J ，故 K-means 单调收敛。

2. 在 PCA 中，对数据做中心化（减去均值）后再求协方差矩阵 $S = \frac{1}{N} X X^T$ 并做特征分解；最大特征值对应的特征向量方向上投影数据的方差最大。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

课程推导 $\text{var}(u^T X) = u^T S u$ ，在约束 $u^T u = 1$ 下最大化得 $S u = \lambda u$ ，即第一主成分是最大的特征值 λ_1 对应的特征向量，其上投影方差恰为 λ_1 ，为各方向中最大。

3. 决策树 ID3 算法在每个结点上选择使"信息增益率（Gain Ratio）"最大的属性进行划分。（2分）

A. 正确（√）

B. 错误（×）

参考答案：错误（×）

解析

ID3 选择使"信息增益 $\text{Gain}(D, A) = \text{Ent}(D) - \text{Ent}(D | A)$ "最大的属性。信息增益率是 C4.5 的划分准则，基尼指数是 CART 的准则，本课只点名不展开计算。

4. 朴素贝叶斯的"朴素"在于假设各特征在给定类别条件下相互独立，从而 $P(x_1, \dots, x_d | c) \approx \prod_i P(x_i | c)$ 。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

这正是条件独立假设，使联合似然可拆成各特征条件概率之积，分类规则为 $c_{NB} = \arg \max_c P(c) \prod_i P(x_i | c)$ 。该假设虽常不严格成立，但实践中分类效果往往很好。

5. 本课程的 SVM 通过求解对偶问题并引入核函数，把线性不可分数据映射到高维空间实现非线性分类。（2分）

A. 正确（√）

B. 错误（×）

参考答案：错误（×）

解析

本课 SVM 只讲"最大间隔 + 合页损失 + 梯度下降"，并不涉及对偶/KKT/核函数/软间隔松弛变量。线性 SVM 直接用合页损失 $\max(0, 1 - y(w^\top x + w_0))$ 加正则项做（次）梯度下降优化。

6. 在 Q-learning 中，更新公式 $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ 里，折扣因子 γ 越接近 1，智能体越"目光短浅"、只看眼前奖励。（2分）

A. 正确（√）

B. 错误（×）

参考答案：错误（×）

解析

恰好相反。 $\gamma \rightarrow 0$ 时智能体"目光短浅"只重视即时奖励； $\gamma \rightarrow 1$ 时"高瞻远瞩"，对远期奖励几乎同等重视。 $\gamma < 1$ 还保证无限步折扣回报收敛。

7. KNN 中 K 取得越大，决策边界越平滑、对噪声越鲁棒；当 $K = N$ （全部样本）时，模型对任何输入都预测全局多数类。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

K 小（如 $K = 1$ ）边界锯齿、对噪声敏感易过拟合； K 增大邻域平均效应增强，边界变平滑；极端 $K = N$ 时所有样本投票，恒输出多数类，失去判别力。

8. 在多层感知机中，若所有隐藏层都不使用非线性激活函数，则无论叠多少层，整个网络在表达能力上仍等价于一个单层线性模型。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

线性变换的复合仍是线性变换（linear•linear=linear），因此堆叠线性层无法拟合 XOR 等非线性边界。必须引入非线性激活（如 ReLU/Sigmoid）才能获得更强表达能力。

9. VAE 的损失由"重构项"与"KL 正则项"两部分组成，其中 KL 项把后验 $q_\phi(z | x)$ 拉向先验 $p(z) = \mathcal{N}(0, I)$ ，使隐空间连续、完整，便于随机采样生成。（2分）

A. 正确（√）

B. 错误（×）

参考答案：正确（√）

解析

VAE 损失为 $-\mathbb{E}_{q_\phi}[\log p_\theta(x | z)] + \text{KL}(q_\phi(z | x) \| p(z))$ 。重构项保证解码像原图，KL 项"填洞铺路"使相邻 z 解码相似、任意采的 z 也能解码出有意义内容。

10. 扩散模型 (Diffusion) 的前向加噪过程是一个含可训练参数的神经网络, 需要通过反向传播学习如何把图像逐步破坏成噪声。 (2分)

A. 正确 (✓)

B. 错误 (×)

参考答案: 错误 (×)

解析

前向加噪过程是固定的、不含可训练参数 (按预设方差 β_t 逐步加高斯噪声); 可训练的是反向去噪网络 $\varepsilon_\theta(x_t, t)$, 它学习预测每一步加入的噪声, 损失为 $\mathbb{E}\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2$ 。

二、选择题 (30 分)

每题3分, 共30分。单选题最优项; 标注[多选]的为多选。

1. 关于无监督学习与聚类, 下列说法正确的是: (3分)

A. A. 聚类需要预先给定每个样本的类别标签

B. B. K-means 隐含假设各簇是各向同性的球形 (因采用平方欧氏距离)

C. C. 簇的个数 K 由算法自动学习得到, 无需人为指定 D. D. PCA 属于聚类算法的一种

参考答案: B

解析

K-means 用平方欧氏距离, 隐含球形等方差假设, 故 B 正确。聚类是无监督的、无标签 (A 错); K 是用户预先指定的超参数 (C 错); PCA 属于降维而非聚类 (D 错)。

2. PCA 中, 若协方差矩阵的特征值 (降序) 为 $\lambda_1 = 7, \lambda_2 = 5, \lambda_3 = 2, \lambda_4 = 1$, 要求保留的累计方差比例不低于 90%, 至少需保留几个主成分? (3分)

A. A. 1 个

B. B. 2 个

C. C. 3 个

D. D. 4 个

参考答案: C

解析

特征值总和 $= 7 + 5 + 2 + 1 = 15$ 。累计方差比例: 前1个 $7/15 \approx 46.7\%$; 前2个 $12/15 = 80\%$; 前3个 $14/15 \approx 93.3\% \geq 90\%$ 才达标。故至少保留 3 个主成分 (等价地, 信息损失 $= 1/15 \approx 6.7\%$, 若只留2个则损失 20% 超标)。

3. 下列关于决策树信息熵的计算, 正确的是 (对数取 $\log_2$): 一个结点含正例 3 个、负例 3 个, 其信息熵 $\text{Ent}(D)$ 为: (3分)

A. A. 0

B. B. 0.5

C. C. 1

D. D. 1.585

参考答案: C

解析

$p_+ = p_- = \frac{1}{2}$, $\text{Ent}(D) = -\frac{1}{2} \log_2 \frac{1}{2} - \frac{1}{2} \log_2 \frac{1}{2} = 1$ 比特。两类等概率时熵最大 (二分类为 1), 不纯度最高。

4. 已知某病在人群中患病率 $P(\text{病}) = 1\%$, 检测灵敏度 $P(\text{阳} | \text{病}) = 0.99$, 误报率 $P(\text{阳} | \text{无病}) = 0.05$ 。某人检测呈阳性, 其真正患病后验概率 $P(\text{病} | \text{阳})$ 约为: (3分)

- A. A. 99%
- B. B. 约 16.7%
- C. C. 约 50%
- D. D. 约 5%

参考答案: B

解析

$P(\text{阳}) = 0.99 \times 0.01 + 0.05 \times 0.99 = 0.0099 + 0.0495 = 0.0594$; $P(\text{病} | \text{阳}) = \frac{0.0099}{0.0594} \approx 0.167$ 。先验极低时即便阳性, 真患病概率仍不高 (基率谬误)。

5. 关于本课程的线性 SVM (最大间隔/合页损失/梯度下降), 下列说法错误的是: (3分)

- A. A. 在归一化使支持向量满足 $w^\top x + w_0 = \pm 1$ 后, 间隔宽度为 $\frac{2}{\|w\|}$
- B. B. 合页损失为 $\max(0, 1 - y(w^\top x + w_0))$, 对已正确且在间隔外的样本损失为 0
- C. C. 训练时通过引入拉格朗日对偶与 KKT 条件求解最优 w
- D. D. 对违反间隔的样本, 其对 w 的 (次) 梯度含 $-y x$ 这一推动项

参考答案: C

解析

本课不讲对偶/KKT, C 超出口径且非本课做法——线性 SVM 直接对"合页损失+L2 正则"做 (次) 梯度下降。A、B、D 均为课程内正确表述。

6. 逻辑回归用 Sigmoid $\sigma(z) = \frac{1}{1+e^{-z}}$ 输出概率, 其参数 w 的梯度下降更新可写为 $w \leftarrow w + \eta \sum_{\ell} (r^{(\ell)} - y^{(\ell)}) x^{(\ell)}$ 。该"误差 $\times$ 输入"形式之所以简洁, 主要因为: (3分)

- A. A. 损失函数取的是平方误差 MSE
- B. B. 交叉熵损失与 Sigmoid 求导时 $\frac{dy}{dz} = y(1-y)$ 恰好约去链式法则中的分母
- C. C. 对参数做了 L2 正则化
- D. D. 使用了 Softmax 归一化

参考答案: B

解析

逻辑回归用交叉熵损失 $-r \log y - (1-r) \log(1-y)$, 链式求导时 Sigmoid 导数 $y(1-y)$ 与交叉熵的分母相消, 得到干净的 $\frac{\partial L}{\partial w_j} = -\sum_{\ell} (r^{(\ell)} - y^{(\ell)}) x_j^{(\ell)}$ 。

7. 下列关于判别式模型与生成式模型的对应, 正确的是: (3分)

- A. A. 逻辑回归、SVM 是生成式模型; GAN、VAE 是判别式模型
- B. B. 判别式模型直接建模 $p(y | x)$ 或决策边界; 生成式模型刻画数据分布 $p(x)$, 可采样生成新样本
- C. C. 生成式模型只能用于分类, 不能生成新数据
- D. D. 判别式模型必须先学会生成数据才能分类

参考答案: B

解析

判别式"在类别间画线" (建 $p(y | x)$, 如逻辑回归/SVM/CNN 分类器); 生成式"刻画整个数据空间的地形" (建 $p(x)$, 如 GAN/VAE/Diffusion, 能采样生成)。

8. 关于 GAN 的对抗训练，下列说法正确的是：（3分）

- A. A. 生成器 G 的目标是让判别器 D 能轻松区分真假图像
- B. B. 当训练达到全局最优、 D 对任意输入都输出 0.5 时，说明 G 已学到真实数据分布
- C. C. 模式坍塌（mode collapse）指 G 生成的样本覆盖了过多的数据模式
- D. D. GAN 训练过程非常稳定，几乎不会出现震荡

参考答案：B

解析

全局最优时 $p_G = p_{data}$ ，判别器无法区分真假，恒输出 0.5（B 对）。 G 想骗过 D （A 错）；模式坍塌是只覆盖部分模式（C 错）；GAN 训练以不稳定/震荡著称（D 错）。

9. [多选] 下列关于 K-means 算法的描述中，正确的有：（3分）

- A. A. 分配步把每个样本归到最近质心所在的簇（winner-takes-all）
- B. B. 算法对初始质心的选取敏感，可能收敛到不同的局部最优
- C. C. K 值越大，目标函数 SSE 一定不会增大
- D. D. 收敛准则之一是：质心几乎不再变化，或 SSE 下降量低于阈值

参考答案：A、B、C、D

解析

A、D 是标准流程与收敛准则；B 正确，K-means 易陷局部最优、对种子敏感（常用多次重启）；C 正确， K 增大簇更细、各样本到质心更近，SSE 单调不增（极端 $K = N$ 时 SSE=0）。

10. [多选] 关于多层感知机训练中的"梯度消失"问题，下列说法正确的有：（3分）

- A. A. Sigmoid 导数最大值仅为 0.25，深层连乘后梯度按指数衰减
- B. B. 反向传播时浅层梯度是众多上游导数之积，层数多则易消失
- C. C. ReLU 在正区间导数为 1，有助于缓解梯度消失
- D. D. 梯度消失会使靠近输入的浅层参数几乎得不到更新

参考答案：A、B、C、D

解析

Sigmoid 导数 ≤ 0.25 ，如 $(0.25)^5 \approx 0.001$ ，多层连乘指数衰减（A、B）；浅层梯度更新近乎停滞（D）；ReLU 正区间导数恒为 1，不引入小于 1 的衰减因子，缓解消失（C）。四项均正确。

三、简答题（20 分）

共20分。

1. 简述 K-means 算法的完整流程（写出分配步与更新步的公式），并说明为什么"更新质心=取簇内样本均值"，以及该算法的两个主要缺点。（5分）

参考答案

算法流程

1. **初始化**：随机选 K 个数据点作为初始质心 $\mu_1, \dots, \mu_K$ (K 为预先指定的超参数)。

2. **分配步 (Assignment)**：把每个样本分到最近质心所在的簇：

$$m_i = \arg \min_k \|x_i - \mu_k\|^2$$

1. **更新步 (Update)**：用当前隶属重算各簇质心（取均值）：

$$\mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$$

1. **重复** 2、3 步直到收敛（质心几乎不变 / 无样本改变归属 / SSE 下降量低于阈值）。

为何质心取均值：目标函数为簇内平方和 $J = \sum_k \sum_{x \in C_k} \|x - \mu_k\|^2$ 。固定隶属关系，对单簇求导并令其为零：

$$\frac{\partial}{\partial \mu_k} \sum_{x \in C_k} \|x - \mu_k\|^2 = -2 \sum_{x \in C_k} (x - \mu_k) = 0 \Rightarrow \mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$$

即让平方误差最小的中心恰为算术均值。

主要缺点：

- 需**预先指定 K** ，且对**初始质心敏感**，易陷入局部最优（常用多次随机重启或 K-means++ 改善）；
- 采用平方欧氏距离，隐含假设簇为**各向同性球形**，对非球形/不同密度的簇、离群点效果差。

2. 请说明 PCA 的核心思想与五步流程，并解释"最大化投影方差"如何归结为协方差矩阵的特征分解。（5分）

参考答案

核心思想：在保留数据方差（信息）尽量多的前提下，把高维数据线性投影到少数几个互相正交的方向（主成分）上，实现降维。

五步流程：

1. **中心化**：每个样本减去均值，使 $\sum_i x_i = 0$ 。

2. **求协方差矩阵**： $S = \frac{1}{N} X X^T$ 。

3. **特征分解**：解 $Su = \lambda u$ ，得特征值 $\lambda_1 \geq \lambda_2 \geq \dots$ 与对应特征向量（主成分方向）。

4. **选 k** ：按累计方差比例 $\frac{\sum_{i=1}^k \lambda_i}{\sum \lambda_i} \geq 95\%$ （即信息损失 $\leq 5\%$ ）确定保留的主成分数。

5. **投影**： $z = U_{1:k}^T x'$ ，得到低维坐标（重构 $\hat{x} = U_{1:k} z$ ）。

为何归结为特征分解：沿单位方向 u 投影后的方差为

$$\text{var}(u^T X) = \frac{1}{N} (u^T X)(u^T X)^T = u^T S u$$

在约束 $u^T u = 1$ 下最大化 $u^T S u$ ，用拉格朗日乘子法令 $\nabla_u (u^T S u - \lambda(u^T u - 1)) = 0$ 得

$$S u = \lambda u$$

即最优方向是 S 的特征向量，且该方向上投影方差恰等于其特征值 λ 。于是取最大特征值对应的特征向量即第一主成分，依次类推。

3. 对比 VAE、GAN、Diffusion 三类生成模型：分别说明其训练准则（如何学习）、采样方式与各自的主要优缺点。（5分）

参考答案

模型	训练准则	采样	优点	主要缺点	
VAE	极大似然：重构损失 + KL 正则 $-\mathbb{E}_{q_\phi}[\log p_\theta(x z)] + \mathrm{KL}(q_\phi \parallel p_z)$	$p(z)$	一步（采 z 后解码）	隐空间连续可解释、训练稳定、可做插值	生成图像偏模糊
GAN	对抗博弈 $\min_G \max_D V(D, G)$ ，生成器与判别器互相竞争	一步，快	图像清晰锐利	训练不稳定、易模式坍塌、无显式似然	
Diffusion	去噪：网络预测每步加入的噪声，损失 $\mathbb{E} \ \epsilon_t - \hat{\epsilon}_t\ ^2$	$\epsilon_t \sim \mathcal{N}(0, \sigma_t^2)$	t^2	多步逐步去噪，慢	质量最高、多样性好、训练稳定 采样慢、计算开销大

关键区别：

- VAE / GAN 都是"一次性（all-at-once）"生成，且隐编码 z 远小于原图；Diffusion 则"从粗到细、逐步"去噪生成，这正是它在 ImageNet 等基准上质量超越 GAN 的原因之一。
- VAE 用编码器输出 μ, σ 并借重参数化技巧 $z = \mu + \sigma \odot \epsilon$ 使采样可微、梯度可回传；GAN 靠判别器提供训练信号；Diffusion 把生成拆成大量简单去噪步。

4. 结合 Q-learning，解释"探索（exploration）与利用（exploitation）"的矛盾，并说明 ϵ -greedy 策略如何平衡二者；再简述折扣因子 γ 的作用。（5分）

参考答案

探索 vs 利用的矛盾：

- 利用（exploitation）：选当前估计 Q 值最高的动作以获取即时高回报；
- 探索（exploration）：尝试尚不熟悉的动作，以发现可能更优但目前 Q 值被低估的策略。

二者矛盾在于：只利用可能困在次优解（从未尝试更好动作），只探索则浪费已知好策略、回报低。智能体需在两者间权衡。

ϵ -greedy：

- 以概率 ϵ 随机选一个动作（探索）；
- 以概率 $1 - \epsilon$ 选当前 Q 值最大的贪心动作 $a = \arg \max_a Q(s, a)$ （利用）。

实践中常让 ϵ 从较大值随训练逐步衰减：早期多探索、后期多利用。

折扣因子 $\gamma \in [0, 1]$ 的作用：度量未来奖励相对即时奖励的重要性。回报 $R_t = \sum_{i \geq t} \gamma^{i-t} r_i$ 。 $\gamma \rightarrow 0$ 时"目光短浅"只看即时奖励； $\gamma \rightarrow 1$ 时"高瞻远瞩"，远期奖励几乎同等重要； $\gamma < 1$ 还保证无限步折扣回报收敛。它出现在更新公式 $Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ 中。

四、计算题（20 分）

共20分。要求写出计算步骤。

1. 给定二维数据集 6 个样本：A(1, 2), B(2, 1), C(3, 3), D(8, 7), E(7, 9), F(9, 8)，用 K-means ($K = 2$ ，平方欧氏距离)。初始质心取 $\mu_1 = (2, 2)$, $\mu_2 = (7, 7)$ 。请完成**一轮迭代**：(1) 分配步——算出每个样本到两质心的平方距离并给出归属；(2) 更新步——算出两个新质心；(3) 若再迭代一次，归属是否会变化？简要说明本轮后是否已收敛。（10分）

参考答案

(1) 分配步：平方距离 $d_k = \|x - \mu_k\|^2$, $\mu_1 = (2, 2), \mu_2 = (7, 7)$ 。

样本	$d_1 = \ x - \mu_1\ ^2$	$d_2 = \ x - \mu_2\ ^2$	归属
A(1, 2)	$(1-2)^2 + (2-2)^2 = 1$	$(1-7)^2 + (2-7)^2 = 61$	C_1
B(2, 1)	$(2-2)^2 + (1-2)^2 = 1$	$(2-7)^2 + (1-7)^2 = 61$	C_1
C(3, 3)	$(3-2)^2 + (3-2)^2 = 2$	$(3-7)^2 + (3-7)^2 = 32$	C_1
D(8, 7)	$(8-2)^2 + (7-2)^2 = 61$	$(8-7)^2 + (7-7)^2 = 1$	C_2
E(7, 9)	$(7-2)^2 + (9-2)^2 = 74$	$(7-7)^2 + (9-7)^2 = 4$	C_2
F(9, 8)	$(9-2)^2 + (8-2)^2 = 85$	$(9-7)^2 + (8-7)^2 = 5$	C_2

得 $C_1 = \{A, B, C\}$, $C_2 = \{D, E, F\}$ 。

(2) 更新步：取簇内均值。

$$\mu'_1 = \frac{1}{3}((1, 2) + (2, 1) + (3, 3)) = \frac{1}{3}(6, 6) = (2, 2)$$
$$\mu'_2 = \frac{1}{3}((8, 7) + (7, 9) + (9, 8)) = \frac{1}{3}(24, 24) = (8, 8)$$

▲

▼

▲

▼

(3) 再迭代一次：以新质心 $\mu'_1 = (2, 2), \mu'_2 = (8, 8)$ 重新分配，A, B, C 仍明显更靠近 (2, 2)，D, E, F 仍更靠近 (8, 8)，归属不变。由于归属不再改变（质心也将不再变化），算法已收敛。

> 注：本轮 μ_1 数值恰好与初值相同 ((2, 2))， μ_2 由 (7, 7) 更新为 (8, 8)；下一轮归属稳定即满足收敛准则。

2. 给定二维数据集 4 个样本: $P_1(2, 2)$, $P_2(6, 4)$, $P_3(3, 1)$, $P_4(5, 5)$, 用 PCA 求第一主成分并把数据投影到 1 维。要求: (1) 中心化并写出协方差矩阵 $S = \frac{1}{N}XX^T$; (2) 求 S 的特征值与 (单位) 特征向量; (3) 给出第一主成分方向, 并算出第一主成分能解释的方差比例; (4) 把 P_2 投影到第一主成分上, 给出其 1 维坐标。 (10 分)

参考答案

(1) 中心化与协方差矩阵

均值 $\bar{x} = \frac{1}{4}(2+6+3+5, 2+4+1+5) = (4, 3)$ 。中心化后:

$$P'_1 = (-2, -1), P'_2 = (2, 1), P'_3 = (-1, -2), P'_4 = (1, 2)$$

协方差 $S = \frac{1}{N} \sum x'x'^T$ ($N=4$):

$$\sum x_1'^2 = 4 + 4 + 1 + 1 = 10, \quad \sum x_2'^2 = 1 + 1 + 4 + 4 = 10, \quad \sum x_1'x_2' = 2 + 2 + 2 + 2 = 8$$

$$S = \frac{1}{4} \begin{bmatrix} 10 & 8 \\ 8 & 10 \end{bmatrix} = \begin{bmatrix} 2.5 & 2 \\ 2 & 2.5 \end{bmatrix}$$

(2) 特征值与特征向量

解 $\det(S - \lambda I) = 0$: $(2.5 - \lambda)^2 - 2^2 = 0 \Rightarrow 2.5 - \lambda = \pm 2$ 。

$$\lambda_1 = 4.5, \quad \lambda_2 = 0.5$$

对 $\lambda_1 = 4.5$: $(2.5 - 4.5)u_1 + 2u_2 = 0 \Rightarrow u_1 = u_2$, 单位化 $u_1 = \frac{1}{\sqrt{2}}(1, 1)$ 。

对 $\lambda_2 = 0.5$: $u_2 = \frac{1}{\sqrt{2}}(1, -1)$ 。

(3) 第一主成分与方差比例

第一主成分方向 $u_1 = \frac{1}{\sqrt{2}}(1, 1)$ (沿 45°)。其方差比例:

$$\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{4.5}{4.5 + 0.5} = \frac{4.5}{5} = 90\%$$

(4) 投影 P_2

用中心化坐标 $P'_2 = (2, 1)$ 投影到 u_1 :

$$z = u_1^T P'_2 = \frac{1}{\sqrt{2}}(1 \cdot 2 + 1 \cdot 1) = \frac{3}{\sqrt{2}} = \frac{3\sqrt{2}}{2} \approx 2.12$$

即 P_2 的第一主成分坐标约为 2.12。

五、系统设计题 (10 分)

共10分。

1. 某共享单车平台希望：(1) 按城市区域把站点/区块聚类，划分出若干"投放分区"以便集中调度与运营；(2) 预测各区域**每小时**的用车需求量，指导早晚高峰的车辆投放与调度。平台已有：各站点经纬度与历史每小时借还车记录、天气、是否工作日/节假日、周边 POI（地铁口/商圈/写字楼/住宅）等。请用本课程模型给出完整方案，覆盖：问题建模 → 数据与特征 → 模型选择（含理由）→ 损失函数 → 训练与优化 → 评估 → 可能问题与改进。（10分）

参考答案

1. 问题建模

本任务拆成两个子问题：

- 子问题 A（无监督·聚类）：把城市区域/站点按空间位置与用车模式聚类，得到 K 个"投放分区"。
- 子问题 B（有监督·回归）：以"区域 × 小时"为样本，预测该时段用车需求量 $\hat{y}$ （连续值），属回归问题。

2. 数据与特征

- 聚类特征：站点经纬度；可补充该站点的日均借/还量、潮汐特征（早高峰净流出、晚高峰净流入）。
- 回归特征：时间特征（小时、星期几、是否工作日/节假日，对周期性的小时用 $\sin / \cos$ 编码）；天气（温度、是否降雨）；区域 POI 类型（地铁口/商圈/写字楼/住宅，独热编码）；滞后特征（上一小时、前一天同时段需求）；所属投放分区编号（来自子问题 A）。
- 预处理：数值特征归一化/标准化（KNN/线性模型尺度敏感）；类别特征独热编码；划分训练/验证/测试（按时间切分，避免未来信息泄露）。

3. 模型选择（课程模型 + 理由）

- 子问题 A：**K-means 聚类**。区域投放分区天然"按相似性分组"，K-means 简单高效、可解释； K 用业务需求或在若干候选值上比较簇内平方和 SSE（肘部）选取。
- 子问题 B：先用**线性回归**作基线（可解释、训练快，配合 L2 正则防过拟合）；为捕捉天气 × 时段等非线性交互，升级为**多层感知机（MLP）**回归（ReLU 激活、单/多隐藏层），其万能逼近能力可拟合复杂非线性需求曲面。

4. 损失函数

- K-means：最小化簇内平方和 $J = \sum_k \sum_{x \in C_k} \|x - \mu_k\|^2$ 。
- 回归：均方误差 $MSE = \frac{1}{N} \sum_{\ell} (y^{(\ell)} - \hat{y}^{(\ell)})^2$ ；线性模型加 L2 正则项 $\frac{\lambda}{2} \|w\|^2$ 。

5. 训练与优化

- K-means：多次随机初始化取 SSE 最小者，交替执行分配/更新步至收敛。
- 线性回归：正规方程闭式解或梯度下降；MLP：**反向传播 + 梯度下降**（mini-batch SGD），学习率调度，必要时早停。

6. 评估

- 聚类：簇内平方和 SSE、肘部法选 K ，并结合业务可解释性（分区是否地理连片、潮汐模式一致）。
- 回归：在按时间划分的测试集上看 MSE/RMSE、MAE，按高峰/平峰分桶查看误差；对比线性基线与 MLP 是否真有提升（防止过拟合）。

7. 可能问题与改进

- 需求强周期性 + 节假日异常：加滞后特征与节假日标志；对小时用周期编码。
- 数据不平衡/长尾（极端天气、活动日）：单独建模或鲁棒损失。
- 过拟合：正则化、早停、交叉验证调超参（ K 、 λ 、隐藏层规模）。
- K-means 对初值与球形假设敏感：多次重启；若分区非球形可改用更细网格再合并。
- 冷启动（新站点）：用其 POI 与最近邻区域特征近似预测。